



République Tunisienne

Ministère de l'Enseignement Supérieur et de la Recherche Scientifique

Université de Carthage

École Supérieure de la Statistique et de l'Analyse de l'Information

Modélisation du Risque de Défaut Client : Mise en place d'un Système de Scoring Crédit

Réalisé par : Hiba Zormati

Année universitaire : 2025–2026

Résumé

Ce projet vise à développer un **modèle de scoring crédit** permettant d'estimer la probabilité de défaut des clients bancaires à partir de données signalétiques et comportementales.

Après un contrôle approfondi de la qualité des données (valeurs manquantes, incohérences, déséquilibre de classes), plusieurs étapes ont été menées : sélection de variables par **Information Value (IV)**, gestion du déséquilibre via **SMOTE**, et modélisation par **régression logistique**.

Le modèle final présente un pouvoir discriminant acceptable avec un **GINI de 0.43** et une **AUC de 0.71**. Les variables les plus influentes sont principalement liées aux soldes bancaires, à la maturité du crédit et aux engagements financiers.

Ce travail met en évidence les enjeux de la modélisation du risque crédit et les limites liées à la qualité et à la structure des données.

Table des matières

1	Introduction	5
1.1	Objectifs	5
2	Méthodologie	5
2.1	Processus de travail	5
2.2	Outils utilisés	5
3	Analyse des Données	5
3.1	Données initiales	5
3.2	Valeurs manquantes	6
3.3	Traitement des valeurs manquantes	6
4	Préparation des Variables	6
4.1	Types de variables	6
4.2	Transformations appliquées	6
4.2.1	Corrections de base	6
4.2.2	Traitement des valeurs extrêmes	6
4.2.3	Normalisation et encodage	7
4.3	Création de nouvelles variables	7
5	Analyse Exploratoire	7
5.1	Répartition de la variable cible	7
5.2	Statistiques descriptives	7
6	Modélisation	7
6.1	Séparation des données	7
6.2	Traitement du déséquilibre	7
6.3	Sélection de variables	8
6.3.1	Information Value (IV)	8
6.3.2	Analyse de corrélation	8
7	Résultats du Modèle	8
7.1	Modèle de régression logistique	8
7.2	Métriques de performance	9
7.3	Matrice de confusion	9
7.4	Analyse des coefficients	9
8	Interprétation des Résultats	9
8.1	Variables importantes	9
8.1.1	Variables augmentant le risque	9
8.1.2	Variables réduisant le risque	10
8.2	Limitations du modèle	10

9	Recommandations	10
9.1	Améliorations du modèle	10
9.2	Utilisation opérationnelle	10
10	Conclusion	10
11	Annexes	11
11.1	Code source	11

25 juillet 2026

Résumé

Ce rapport présente l'analyse complète des données de crédit et le développement d'un modèle de scoring pour prédire le risque de défaut des clients. Le travail comprend la préparation des données, l'analyse exploratoire, le traitement des variables, la modélisation par régression logistique et l'évaluation des performances. Le modèle final présente un pouvoir discriminatoire acceptable avec un GINI de 0.4298.

Table des matières

1 Introduction

L'objectif de cette étude est de développer un modèle de scoring permettant d'évaluer le risque de défaut des clients sur une période de 12 mois. Ce modèle s'appuie sur les données historiques de la base SNI contenant 5,752 observations initiales et 29 variables.

1.1 Objectifs

- Analyser et préparer les données pour la modélisation
- Identifier les variables les plus prédictives du risque de défaut
- Développer un modèle de scoring fiable
- Évaluer les performances du modèle
- Interpréter les résultats pour une utilisation opérationnelle

2 Méthodologie

2.1 Processus de travail

Le projet a suivi une méthodologie structurée en plusieurs étapes :

1. Chargement et exploration initiale des données
2. Nettoyage et traitement des données
3. Analyse exploratoire (EDA)
4. Préparation des variables
5. Sélection de variables
6. Modélisation (Régression Logistique)
7. Évaluation des performances
8. Interprétation des résultats

2.2 Outils utilisés

- Python 3.x
- Bibliothèques : pandas, numpy, scikit-learn, matplotlib, seaborn
- Environnement : Google Colab / Jupyter Notebook

3 Analyse des Données

3.1 Données initiales

- Nombre d'observations initial : 5,752
- Nombre de variables initial : 29
- Doublons identifiés : 27 (supprimés)
- Observations finales : 5,725

3.2 Valeurs manquantes

La distribution des valeurs manquantes est présentée ci-dessous :

Variable	Valeurs manquantes	Taux (%)
Profession	4,588	79.8%
Code tribunal	5,118	89.0%
Interdiction cheque	5,685	98.8%
Type de revenu	1,978	34.4%
Catégorie sociale	1,775	30.9%
Revenus mensuels	2,265	39.4%

TABLE 1 – Variables avec taux de valeurs manquantes élevés

3.3 Traitement des valeurs manquantes

- Variables catégorielles : remplacement par "Inconnu"
- Variables numériques : remplacement par la médiane
- Date de naissance : remplacement par la date médiane
- Suppression de la variable "Code tribunal" (trop de valeurs manquantes)

4 Préparation des Variables

4.1 Types de variables

- Variables numériques : 15 variables
- Variables catégorielles : 14 variables
- Variables datetime : 2 variables

4.2 Transformations appliquées

4.2.1 Corrections de base

- Maturité : valeurs négatives remplacées par 0
- Variables financières : vérification des valeurs négatives incohérentes

4.2.2 Traitement des valeurs extrêmes

- Transformation logarithmique pour :
 - CRD (Crédit Restant Dû)
 - Solde moyen
 - Revenus mensuels
 - Engagement
 - Solde arrêté
- Winsorisation pour "nb_pret" (limites à 1%)
- Capping pour "CRD/gar" au 99ème percentile

4.2.3 Normalisation et encodage

- Standardisation (StandardScaler) pour toutes les variables numériques
- One-Hot Encoding pour les variables catégorielles
- Suppression de la première catégorie pour éviter la multicollinéarité

4.3 Création de nouvelles variables

- Âge calculé à partir de la date de naissance
- Classes d'âge : 18-24, 25-34, 35-44, 45-54, 55-64, 65+
- Variable cible "flag_default" : défaut si DPD 12M > 90 jours

5 Analyse Exploratoire

5.1 Répartition de la variable cible

- Non-défaillants (0) : 5,600 observations (97.9%)
- Défaillants (1) : 116 observations (2.1%)
- Problème de classe déséquilibrée

5.2 Statistiques descriptives

Les principales statistiques des variables numériques après transformation :

Variable	Moyenne	Écart-type	Min	Max
CRD (log)	14.17	1.48	0.00	18.18
PNU	171,523	1,624,462	0	76,982,378
Maturité	4.32	24.91	0	25
Garantie max	1,497,995	3,782,216	0	215,783,500
Age relation	46.14	56.61	0	311
Solde moyen (log)	11.23	0.76	-14.93	15.92
Revenus mensuels (log)	10.43	0.79	0	12.64

TABLE 2 – Statistiques descriptives des principales variables

6 Modélisation

6.1 Séparation des données

- Ensemble d'entraînement : 70% des données (4,007 observations)
- Ensemble de test : 30% des données (1,718 observations)
- Stratification appliquée pour préserver la distribution de la variable cible

6.2 Traitement du déséquilibre

- Utilisation de SMOTE (Synthetic Minority Over-sampling Technique)
- Génération d'échantillons synthétiques pour la classe minoritaire
- Équilibrage 50/50 sur l'ensemble d'entraînement

6.3 Sélection de variables

6.3.1 Information Value (IV)

Les variables ont été sélectionnées sur la base de leur Information Value. Seules les variables avec $IV > 0.02$ ont été retenues :

Variable	IV	Interprétation
Solde arrêté	1.8871	Forte puissance prédictive
Solde moyen	1.1708	Forte puissance prédictive
CRD/eng	0.5238	Moyenne puissance prédictive
Maturité	0.5134	Moyenne puissance prédictive
Age relation	0.3841	Moyenne puissance prédictive
Âge	0.3232	Faible puissance prédictive
CRD/gar	0.3091	Faible puissance prédictive
CRD/gar_cap	0.3091	Faible puissance prédictive
Garantie max	0.1690	Faible puissance prédictive
Revenus mensuels	0.1632	Faible puissance prédictive
CRD	0.1536	Faible puissance prédictive
Engagement	0.0794	Très faible puissance prédictive
PNU	0.0670	Très faible puissance prédictive

TABLE 3 – Information Value des variables sélectionnées

6.3.2 Analyse de corrélation

Une matrice de corrélation a été analysée pour identifier les variables fortement corrélées. Les corrélations élevées suivantes ont été notées :

- CRD/eng et Maturité : 0.51
- CRD et Engagement : 0.72
- CRD/gar et CRD/gar_cap : 0.78

7 Résultats du Modèle

7.1 Modèle de régression logistique

- Algorithme : Régression Logistique
- Solveur : LBFGS
- Maximum d'itérations : 1000
- Variables retenues : 13 variables

Métrique	Valeur	Interprétation
AUC (Area Under Curve)	0.7149	Discriminant acceptable
GINI	0.4298	Pouvoir discriminant modéré
Accuracy	0.9785	Excellent (mais biaisé)
Précision (classe 0)	0.9796	Bonne
Rappel (classe 0)	0.9988	Excellent
F1-Score (classe 0)	0.9891	Excellent

TABLE 4 – Performances du modèle sur l'ensemble de test

		Prédit	
		Non-défaillant	Défaillant
2*Réel	Non-défaillant	1,681 (TN)	2 (FP)
	Défaillant	35 (FN)	0 (TP)

TABLE 5 – Matrice de confusion

Variable	Coefficient	Impact sur le risque
CRD	0.6646	Augmente le risque
Engagement	0.3753	Augmente le risque
Age relation	0.2945	Augmente le risque
CRD/gar_cap	0.1024	Augmente légèrement le risque
Revenus mensuels	0.0761	Augmente légèrement le risque
CRD/eng	0.0748	Augmente légèrement le risque
Âge	0.0205	Impact marginal
PNU	-0.1675	Réduit légèrement le risque
Solde arrêté	-0.2461	Réduit le risque
Garantie max	-0.3095	Réduit le risque
CRD/gar	-0.3198	Réduit le risque
Solde moyen	-0.5512	Réduit fortement le risque
Maturité	-0.8491	Réduit fortement le risque

TABLE 6 – Coefficients de la régression logistique

7.2 Métriques de performance

7.3 Matrice de confusion

7.4 Analyse des coefficients

8 Interprétation des Résultats

8.1 Variables importantes

8.1.1 Variables augmentant le risque

- **CRD** : Coefficient positif élevé (0.6646) - plus le crédit restant dû est élevé, plus le risque de défaut est important
- **Engagement** : Coefficient positif (0.3753) - les engagements financiers plus élevés augmentent le risque
- **Age relation** : Coefficient positif (0.2945) - les relations bancaires plus longues présentent paradoxalement plus de risque

8.1.2 Variables réduisant le risque

- **Maturité** : Coefficient négatif fort (-0.8491) - les crédits plus courts présentent moins de risque
- **Solde moyen** : Coefficient négatif (-0.5512) - les clients avec des soldes moyens plus élevés présentent moins de risque
- **Garantie max** : Coefficient négatif (-0.3095) - la présence de garanties réduit le risque

8.2 Limitations du modèle

- **Déséquilibre des classes** : Modèle biaisé vers la prédiction de la classe majoritaire
- **Absence de vrais positifs** : Aucun défaut correctement prédit sur l'ensemble de test
- **Trop de faux négatifs** : 35 défauts non détectés
- **Données manquantes** : Variables importantes avec beaucoup de valeurs manquantes

9 Recommandations

9.1 Améliorations du modèle

1. **Collecte de données** : Améliorer la qualité des données professionnelles et des revenus
2. **Traitement du déséquilibre** : Essayer d'autres techniques (ADASYN, Random Under-Sampling)
3. **Modélisation** : Tester d'autres algorithmes (Random Forest, XGBoost)
4. **Seuil de décision** : Ajuster le seuil de classification (actuellement 0.5)
5. **Variables additionnelles** : Intégrer des variables comportementales et externes

9.2 Utilisation opérationnelle

1. **Monitoring** : Suivi régulier des performances du modèle
2. **Validation** : Validation sur des données récentes
3. **Interprétation** : Création de règles métier basées sur les coefficients
4. **Déploiement** : Intégration dans les systèmes de décision

10 Conclusion

Ce projet a permis de développer un modèle de scoring crédit avec un pouvoir discriminant acceptable ($\text{GINI} = 0.4298$). Bien que le modèle présente certaines limitations liées au déséquilibre des classes et à la qualité des données, il identifie des relations importantes entre les variables financières et le risque de défaut.

Les variables les plus prédictives sont le solde arrêté, le solde moyen et la maturité du crédit. Le modèle montre que les crédits à court terme avec des soldes moyens élevés présentent moins de risque, tandis que les engagements financiers importants augmentent le risque.

Des améliorations sont nécessaires, notamment dans la collecte des données et le traitement du déséquilibre des classes, pour augmenter la capacité du modèle à détecter les défauts tout en maintenant une bonne précision globale.

11 Annexes

11.1 Code source

Les principales étapes incluent :

1. Chargement et exploration des données
2. Nettoyage et traitement
3. Analyse exploratoire
4. Préparation des variables
5. Sélection de variables par IV
6. Modélisation par régression logistique
7. Évaluation des performances
8. Calcul des scores